

ESCUELA
POLITÉCNICA
NACIONAL

Estadística y Programación para Ciencia de Datos

Laboratorio #1

Realizado por:

Josue Palma Zambrano

18 de octubre de 2026

Enlace del repositorio:

`https://github.com/josuepalma23/Lab1-EstII`

1. Introducción

RetailAndina S.A, una empresa multipropósito, junto a su departamento de Business Intelligence pide a un empleado con conocimientos en Ciencia de Datos un análisis de diferentes indicadores a partir de la reciente ingesta de datos correspondiente a las ventas de la semana. En concreto, dichos indicadores servirán de ayuda para describir los datos y generar insights valiosos a nivel gerencial.

Por otro lado, los datos presentan un carácter variado, debido a su diferente origen, son recibidos por la empresa en diferentes formatos (CSV, excel y json), lo que requerirá que el empleado aplique sus conocimientos relacionados a la lectura de estos archivos de forma eficiente, además de diferentes técnicas de visualización, que describirán a los datos y generarán salidas útiles para que el empleado pueda cumplir con el objetivo solicitado.

2. Objetivos

Objetivo General:
Aplicar sentencias básicas de código en Python y R utilizando librerías de visualización y análisis de datos.

Objetivos Específicos:

- Leer archivos csv, xlsx, y json con librerías de análisis de datos en Python y R.
- Generar pequeñas descripciones de los datos utilizando métodos como head y dim en ambos lenguajes.
- Generar reportes sobre ventas utilizando métodos de las librerías de ambos lenguajes.

3. Desarrollo de la Práctica

Para la presente práctica, utilicé el entorno de Google Colab, tanto para Python como para R.

3.1. Lectura de Archivos

Primero, leí los archivos de datasets en los tres formatos mencionados, tanto en Python como en R usando Google Colab:

Lectura de CSV:

Python:

```
## Lectura del CSV en Python y descripciones básicas de los datos
ventas = pd.read_csv("data/ventas.csv")
print(ventas.head())
print(ventas.shape)
print(ventas.dtypes)
```

R:

```
# Lectura del CSV en Python y descripciones básicas de los datos
library(readr)
ventas <- readr::read_csv("data/ventas.csv")
dim(ventas)
head(ventas)
```

Lectura de Excel:

Python:

```
## Lectura de excel en Python y descripciones básicas
ventas = pd.read_excel("data/ventas.xlsx",
                       sheet_name="ventas")
print(ventas.head())
print(ventas.shape)
print(ventas.dtypes)
```

R:

```
# Lectura de excel en R y descripciones básicas
library(readxl)
ventas <- read_excel("data/ventas.xlsx")
```

```python
import pandas as pd

ventas = pd.read_csv("data/ventas.csv")
print("\nPrimeros datos del archivo")
print(ventas.head())

# imprimir dimensiones
print("\nNumero de filas y columnas en tupla")
print(ventas.shape)

print("\nTipos de datos")
print(ventas.dtypes)
```

```
...
Primeros datos del archivo
           sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4            Cuenca  Sierra    8540       210

Numero de filas y columnas en tupla
(5, 4)

Tipos de datos
sucursal    object
region      object
ventas       int64
clientes     int64
dtype: object
```

Figura 1: Lectura de CSV en Python

```
%%R
library(readr)
ventas <- readr::read_csv("data/ventas.csv")
dim(ventas)
head(ventas)
```

```
Rows: 5 Columns: 4
── Column specification ────────────────────────────────────────────────────────
Delimiter: ","
chr (2): sucursal, region
dbl (2): ventas, clientes

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
# A tibble: 5 × 4
  sucursal         region ventas clientes
  <chr>            <chr>   <dbl>    <dbl>
1 Quito Norte      Sierra  12450      320
2 Quito Sur        Sierra   9870      265
3 Guayaquil Centro Costa   15200      410
4 Guayaquil Norte  Costa   13980      372
5 Cuenca           Sierra   8540      210
```

Figura 2: Lectura de CSV en R y descripciones básicas

```
import pandas as pd
ventas = pd.read_excel("data/ventas.xlsx", sheet_name="ventas")

print(ventas.head())
print(ventas.shape)
print(ventas.dtypes)
```

```
            sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4           Cuenca  Sierra    8540       210
(5, 4)
sucursal    object
region      object
ventas       int64
clientes     int64
dtype: object
```

Figura 3: Lectura de datos en formato Excel y descripciones básicas

```
head(ventas)
dim(ventas)
str(ventas)
```

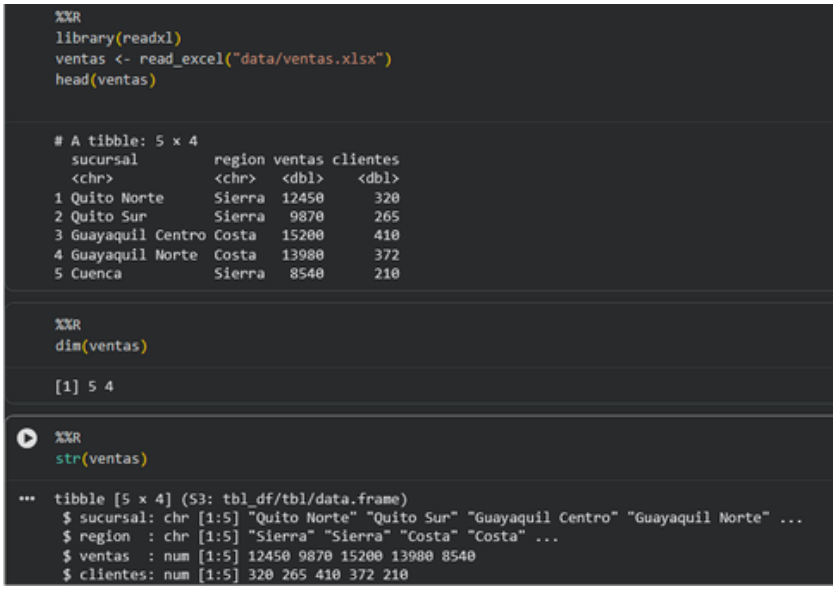


Figura 4: Lectura de datos en Excel en R y descripciones básicas

Lectura de Json:

Python:

```
with open("data/ventas.json", encoding="utf-8") as f:
  datos = json.load(f)

# normalizar el json
ventas = pd.json_normalize(datos)
print(ventas.head())

# descripciones del archivo json
print("\nDimension del archivo json")
print(ventas.shape)
print("\nTipos de datos del archivo")
print(ventas.dtypes)
```

```python
import json
import pandas as pd

with open("data/ventas.json", encoding="utf-8") as f:
  datos = json.load(f)

# normalizar el json
ventas = pd.json_normalize(datos)
print(ventas.head())

print("\nDimension del archivo json")
print(ventas.shape)
print("\nTipos de datos del archivo")
print(ventas.dtypes)
```

```
           sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4            Cuenca  Sierra    8540       210

Dimension del archivo json
(5, 4)

Tipos de datos del archivo
sucursal    object
region      object
ventas       int64
clientes     int64
dtype: object
```

Figura 5: Lectura de datos en Json en Python y descripción de tipos/dimensión de archivo

R:

```r
# Declaracion de la libreria
library(jsonlite)

# Lectura de datos
ventas <- fromJSON("data/ventas.json")
```

```
# Descripciones básicas
head(ventas)
dim(ventas)
str(ventas)
```

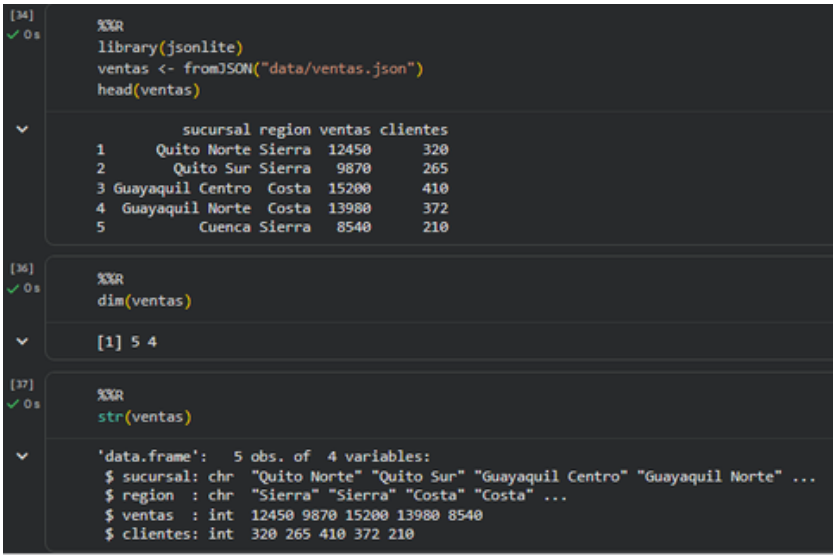


Figura 6: Lectura de datos en formato JSON en R y descripciones básicas de dimensión y tipos.

3.2. Inspecciones

Durante esta parte del laboratorio, utilicé los conocimientos aprendidos sobre las sentencias básicas, tanto en Python como en R con el objetivo de generar reportes útiles a nivel de negocio, en concreto, se destaca crear una nueva columna dentro del dataset y calcular un nuevo valor llamado ticket.

Python:

```
## añadí otra columna a ventas y calculé el ticket.
ventas["ticket"] = ventas["ventas"] / ventas["clientes"]

## utilicé .loc e idmax() para obtener la sucursal con mayor ventas.
print("Sucursal con mayor ventas",
```

```
      ventas.loc[ventas["ventas"].idxmax(), "sucursal"])

## hice lo mismo para la sucursal con menor ventas.
print("Sucursal con menor ventas",
      ventas.loc[ventas["ventas"].idxmin(), "sucursal"])

## utilicé groupby para obtener la región con más ventas.
ventas_per_region = ventas.groupby("region")["ventas"].sum()
region_max = ventas_per_region.idxmax()
```

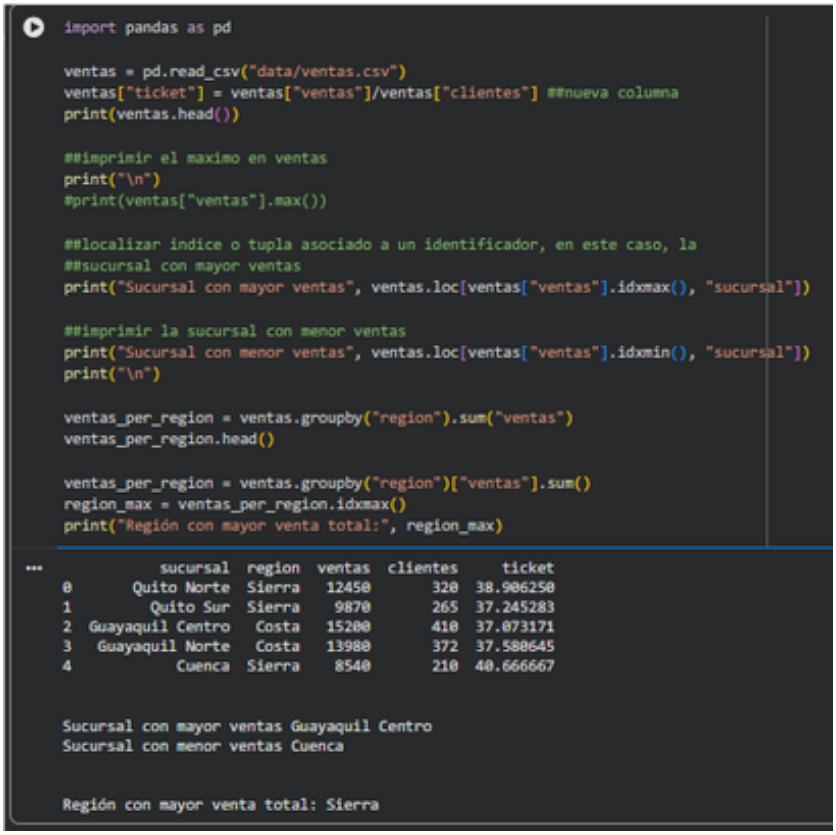


Figura 7: Inspección de los datos en Python, diversos métodos y técnicas para obtener insights.

R:

```r
ventas <- read.csv("data/ventas.csv")
str(ventas)
ventas$ticket <- ventas$ventas / ventas$clientes
head(ventas)

aggregate(ventas ~ sucursal, data = ventas, mean)
sum(ventas$ventas) / sum(ventas$clientes)

ventas$sucursal[which.max(ventas$ventas)]
ventas$sucursal[which.min(ventas$ventas)]

regiones <- aggregate(ventas ~ region, data = ventas, sum)
regiones$region[which.max(regiones$ventas)]
```

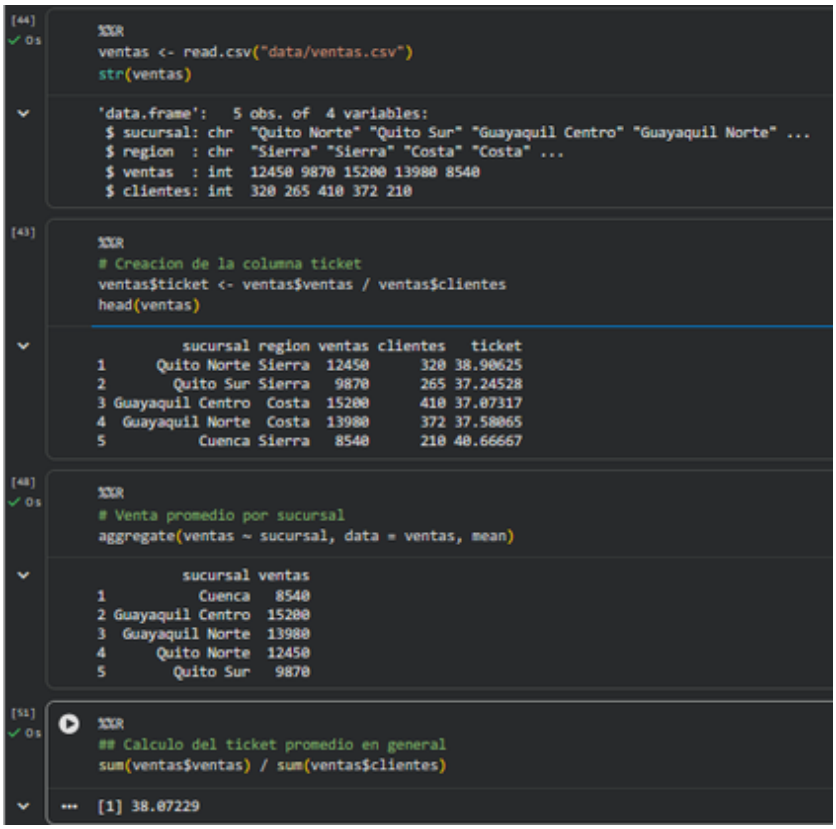


Figura 8: Inspección de datos en R, creación de columnas, reportes de ventas.

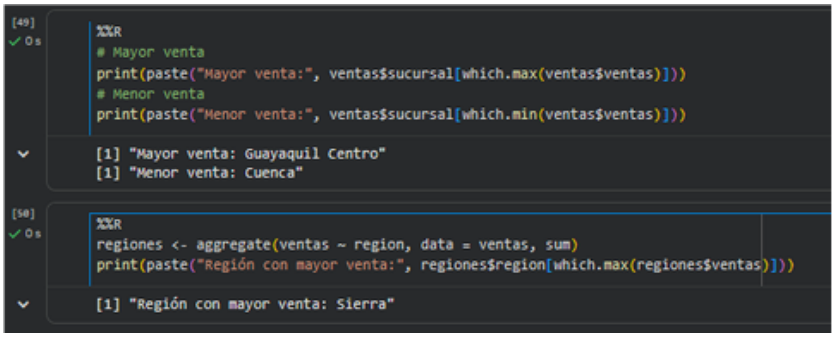


Figura 9: Inspección de datos en R, reporte de mayores y menores ventas, reporte de región con mayor ventas.

3.3. Preguntas propuestas

1. **¿Cuántas filas y columnas tiene la tabla en cada uno de los tres formatos?**
   La tabla está compuesta por 5 filas y 4 columnas en cada uno de los tres formatos.

2. **¿Fue igual en los tres? ¿Por qué?**
   Porque a pesar de ser archivos con diferentes formatos, tienen los mismos datos dentro y al ser analizados por ambos lenguajes devuelven el mismo resultado.

3. **¿Qué tipo de datos se infirió para ventas y clientes? ¿Qué indicaría que salieran como texto?**
   Se infirió a ambos como int, si se describiera como texto nos indicaría que estos datos necesitan limpieza o depuración, debido a que en el enfoque de negocio, estos valores deberían siempre ser numéricos.

4. **En Python, ¿qué estructura devuelve json.load y por qué hay que .ªplanarla¿**
   Devuelve un diccionario de Json. Es importante aplanarla debido a que al ser exportada, un diccionario Json suele tener estructuras anidadas; si los aplanamos, obtendremos un formato tabular que ayuda a convertir esas claves anidadas a columnas independientes, además de facilitar su limpieza, ya que navegar por columnas independientes es mucho más fácil que por estructuras anidadas complejas.

5. **¿Para qué sirve indicar sheet_name/sheet al leer Excel?**
   Según Ask Python, (2026), nos sirve para decirle al programa exactamente qué hoja debe mirar. En análisis de datos suelen existir datasets y archivos con múltiples hojas; sin esto sería muy complicado realizar un análisis de datos de una hoja en concreto de un archivo Excel más grande.

6. **¿Qué diferencia ves entre leer en Python y leer en R (conceptos, no sintaxis)?**
   Me parece que R es un poco más difícil de entender que Python en el sentido de conceptos. Por ejemplo, en Python es mucho más fácil entender en general lo que está pasando en el código y qué operaciones se están realizando. En mi opinión, cuando escribo en R es como si le estuviera diciendo al programa instrucciones como en una notación un tanto matemática, como la que se utiliza en otros software estadísticos como Stata.

4. ¿Qué aprendí con esta práctica?

Esta práctica fue como tal mi primer contacto con el lenguaje R. Tanto su sintaxis como su lógica y sus entornos eran en su mayoría extraños para mí; por otro lado, aprendí a realizar reportes estadísticos a partir de datasets utilizando la librería Pandas, cosa que no había realizado antes. En el pasado, solo había utilizado pandas para hacer descripciones rápidas o para crear dataframes, pero realmente nunca profundicé en lo útil que podría ser.

Resumen ejecutivo

Recibí tres archivos de distintos tipos con información relacionada a ventas semanales, después de los análisis respectivos, se encontró que la región con más ventas fue la sierra, por lo tanto, como desarrollador, sugeriría realizar campañas de marketing más intensas en todas las regiones pero enfocándose especialmente en la costa y amazonía, para llevar el nivel de ventas al mismo lugar en el que está la sierra.

1. ¿Los tres formatos contienen la misma información?

Carga los tres archivos (CSV, JSON y Excel) en Python y en R, y compara dimensiones y estructura. Completa la tabla:

Formato	Origen	Filas	Columnas	Lectura en código
CSV	ERP de sucursales	5	4	(5, 4)
JSON	API de fidelización	5	4	(5, 4)
Excel	Consolidado de finanzas	5	4	(5, 4)

Responde: ¿la estructura interna del archivo (texto plano, anidada, binaria) cambia el contenido?
No, no cambia su contenido, sino su manera de expresarlo y visualizarlo, se cambia la manera en la que se organiza el contenido.

2. Tipos de datos y calidad

Inspecciona los tipos que infiere cada lenguaje. Completa la tabla y comenta si los tipos son los esperados para cada variable:

Variable	Tipo inferido (Python)	Tipo inferido (R)	Interpretación
ventas	int64	dbl	Tipo de dato esperado bajo la lógica de negocio.
clientes	int64	dbl	Tipo de dato esperado bajo la lógica de negocio.
sucursal	object	chr	Tipo de dato esperado bajo la lógica de negocio.
region	object	chr	Tipo de dato esperado bajo la lógica de negocio.

¿Qué habría indicado un dato sucio si, por ejemplo, ventas llegara como texto?

3. Particularidades técnicas encontradas

Anota qué encontraste al leer cada formato (una nota por formato): ¿el JSON llegó como tabla? ¿hubo que indicar una hoja en el Excel? ¿cómo se expresan las categóricas en cada lenguaje?

4. Indicadores para la reunión del lunes

Calcula los indicadores con los datos consolidados y completa la tabla:

Indicador	**Valor**
Venta promedio por sucursal	12008.0
Ticket promedio (ventas ÷ clientes)	38.07
Sucursal con mayor venta	Guayaquil Centro
Sucursal con menor venta	Cuenca
Región con mayor venta total	Sierra

5. Conclusiones

1. Logré leer datos variados con agilidad, tanto en Python como en R.
2. Aprendí el valor de la realización de reportes estadísticos en el Análisis de Datos y sobre todo en la Ciencia de Datos en general.

6. Bibliografía

- Bugdani, T. (2026, September 30). Pandas read_excel(): Read an Excel File into a Pandas DataFrame. AskPython. `https://www.askpython.com/python-modules/pandas/pandas-read-excel`
- Pandas documentation — pandas 3.0.6 documentation. (n.d.). Pydata.org. Retrieved October 18, 2026, from `https://pandas.pydata.org/docs/`
- Pandas step by step guide. (2025, February 7). GeeksforGeeks. `https://www.geeksforgeeks.org/pandas/pandas-step-by-step-guide/`

Declaración de IA:

Se utilizó el modelo Gemini de Google en este laboratorio únicamente para migrar el formato de texto, originalmente hecho en Word a texto en LaTeX para su posterior exportación.